

Projection economique

Cout d'exploitation de Baitly

Couts fixes & recurrents a zero client . unit economics . projections par paliers

Date	14 juin 2026
Objet	Combien coute l'exploitation du logiciel - a 0 client puis selon le nombre de clients
Methode	Modele parametre : infra (clenzy-infra) + drivers variables (config IA/email) + tarifs publics approx.
Unite	EUR/mois (ordres de grandeur). 1 client = 1 organisation (conciergerie/hote)
Important	Estimations - pas des prix vendeur exacts. Couts pass-through (Stripe, commissions OTA) exclus du bur

Confidentiel - usage interne. Tous les montants sont des ORDRES DE GRANDEUR (infra single-node, tarifs cloud/SaaS approximatifs, cutoff connaissance 2026-01). Le modele est parametre (hypotheses explicites p.2) et ajustable. Les couts pass-through (frais Stripe sur les paiements voyageurs, commissions OTA, abonnements IoT/compta payes par le client) ne sont PAS du cout d'exploitation Baitly.

Synthese (en 30 secondes)

- **A 0 client**, le logiciel coute environ **42 EUR/mois** (~498 EUR/an) : c'est le socle infra always-on (serveur unique, BDD, Redis, Kafka, Keycloak, monitoring self-hosted) + domaine. Quasiment incompressible.

- **Les couts fixes one-time sont quasi nuls** pour un SaaS auto-heberge : nom de domaine (~15 EUR/an), TLS gratuit (Let's Encrypt), monitoring inclus (Prometheus/Grafana self-hosted), Cloudflare Free.

- **Le cout marginal par client est faible** : ~1-5 EUR/client/mois, car (1) le budget de tokens IA est aujourd'hui plafonne a 100k/org/mois (**valeur par defaut a recalibrer - cf. etude section 4**), (2) l'email Brevo a un tier gratuit genereux, (3) le monitoring ne facture rien.

- **A 100 clients** : ~220 EUR/mois ; **a 1000 clients** : ~1596 EUR/mois (hors options activables et pass-through). L'economie d'exploitation est tres lean tant qu'on reste mono-noeud + photos a externaliser en S3 a l'echelle.

- **Ce qui peut faire deraper** : IA intensive (budget releve / multi-agent active -> x6-10 le poste IA), Channex par-logement si active, e-signature QTSP / KYC par usage, et le palier infra (BDD managee + S3) au-dela de ~250-500 clients.

1. Hypotheses & methode

Le modele additionne quatre postes : **infra serveur** (paliers selon la charge), **email** (Brevo, tier gratuit puis paliers), **ops/backup**, et **variable IA+RAG** (par client). Hypotheses cles (ajustables) :

Logements moyens / client	8	conciergerie early-stage
Cout IA / client / mois (standard)	~1.0 EUR	sous le cap 100k tokens/org, Claude Sonnet + cache prompt 5 min
Cout IA / client / mois (intensif)	~8 EUR	budget x10 (~1M tokens) ou multi-agent active (8 specialistes)
Embeddings RAG / client / mois	~0.10 EUR	Voyage, on-demand, cache - negligeable
Emails / client / mois	~96	confirmations + rappels (~8 logements x 3 resa x 4)
Domaine (amorti)	~1.5 EUR/mois	~15-20 EUR/an

Reperes tarifaires utilises (ordres de grandeur, tarifs publics approx.)

- **Serveur** : OVH/Hetzner/Scaleway 16 Go ~ 20-50 EUR/mois ; 32 Go ~ 40-70 ; BDD manatee + S3 a l'echelle.
- **Claude Sonnet** : ~3 USD / 1M tokens entree, ~15 USD / 1M sortie ; cache lecture ~10%. Cap 100k tokens/org/mois.
- **Voyage embeddings** : ~0,18 USD / 1M tokens. **Brevo** : free ~9k emails/mois, puis ~19-65 EUR/mois.
- **Cloudflare** Free (0) ; **Let's Encrypt** 0 ; **monitoring** self-hosted (0 SaaS, consomme la RAM du noeud).

2. Cout a ZERO client (le socle incompressible)

Ce que coute le logiciel meme sans aucun utilisateur : l'infrastructure always-on doit tourner en permanence. Le pms-server fait tourner 4 JVM cote infra (Spring, Keycloak, Kafka, kafka-ui) + Postgres (pgvector) + Redis + la pile observabilite - d'ou un besoin RAM ~8-16 Go sur un noeud unique.

Couts FIXES (one-time / CapEx)

Nom de domaine (1re annee)	~15 EUR	clenzy.fr/baitly + sous-domaines (annuel)
Certificat TLS	0 EUR	Let's Encrypt (certbot, auto)
Mise en place serveur	0 EUR (cash)	self-hosted ; cout = temps d'ingenierie
Materiel	0 EUR	aucun (sauf capteurs Baitly Hardware, hors logiciel)
Total fixe one-time (cash)	~15-50 EUR	

Couts RECURRENTS a 0 client (mensuels)


Serveur (noeud unique 16 Go)	~35 EUR	OVH actuel / Hetzner / Scaleway
Backups offsite + ops	~5 EUR	snapshot/objet (auj. backups locaux pg_dump)
Cloudflare	0 EUR	tier Free suffisant
Monitoring (Prometheus/Grafana/Loki)	0 EUR	self-hosted, inclus dans le noeud
Domaine (amorti)	~1,5 EUR	~15-20 EUR/an
Cles IA (idle)	~0 EUR	pay-as-you-go : 0 sans usage (hors tests dev)
Email (Brevo)	0 EUR	tier gratuit
Total recurrent / mois (0 client)	~42 EUR (~498 EUR/an)	

Note : prevoir une petite enveloppe IA de dev/tests (~5-20 EUR/mois) tant que vous developpez avec l'assistant. Elle disparaît a l'arret de l'usage (pay-as-you-go).

3. Projection par nombre de clients

Scenario **standard** (IA sous le cap 100k tokens/org). Le TOTAL inclut infra + email + ops + IA/RAG + domaine. Hors options activables (Channex, e-signature, KYC, e-invoicing par pays) et hors pass-through (Stripe, commissions OTA) - details en section 5.

Clients	Logements~	Infra	Email	Ops/backup	IA+RAG	Domaine	TOTAL /mois	/an	/client
0 (base)	-	35	0	5	0	2	42 EUR	498	-
1	8	35	0	5	1	2	43 EUR	511	42.6
10	80	35	0	5	11	2	52 EUR	630	5.2
50	400	35	0	5	55	2	96 EUR	1 k	1.9
100	800	75	19	15	110	2	220 EUR	3 k	2.2
250	2000	75	65	15	275	2	432 EUR	5 k	1.7
500	4000	170	65	40	550	2	826 EUR	10 k	1.7
1000	8000	350	65	80	1100	2	1596 EUR	19 k	1.6



Lecture : le socle (~42 EUR/mois) domine a faible volume (le cout/client tombe vite : ~5 EUR a 10 clients, ~2.2 EUR a 100, ~1.6 EUR a 1000). Le poste IA devient le 1er variable a l'echelle, mais reste borne par le budget de tokens.

Le poste IA ci-dessus suppose l'usage **borne par le cap actuel** (~1 EUR/client). Le cap n'etant pas definitif, la **section 4** chiffre l'usage reel : pour un assistant reellement utilise, compter plutot ~3 EUR/client/mois (Sonnet) ou ~1 EUR (Haiku) - a recalibrer par plan.

4. Etude approfondie du cout IA (tokens)

Le cap de 100k tokens/org/mois n'est pas definitif - il doit etre recalibre. Cette section modelise le cout reel a partir de la configuration : **max_tokens 4096/tour, jusqu'a 5 iterations d'outils par message** (moyenne retenue ~2 appels LLM), et le **cache prompt** (system + outils + prefixe, TTL 5 min). Hypothese par message : ~1500 tokens entree frais + ~4000 tokens caches (lus a ~10%) + ~700 tokens sortie, soit **~12 400 tokens 'comptes' par message**.

Cout par message selon le modele

Modele	Input \$/M	Cache \$/M	Output \$/M	\$ / message	EUR / message
Claude Sonnet (defaut actuel)	3.00	0.30	15.00	\$0.0324	~0.030
Claude Haiku (economique)	1.00	0.10	5.00	\$0.0108	~0.010
Nova Lite / OpenAI-compat (tres eco)	0.10	0.01	0.40	\$0.0009	~0.001

Le choix du modele fait un facteur ~3 (Haiku) a ~30 (Nova) sur le cout/message. Le cache prompt reduit l'input repete a ~10% de son cout (deja actif dans AnthropicChatProvider).

Cout par client/mois selon l'intensite d'usage

Profil	Msg/mois	Tokens/mois	EUR/client (Sonnet)	EUR/client (Haiku)	vs cap 100k
Leger	20	248 k	~0.6	~0.2	x2
Standard	100	1.24 M	~3.0	~1.0	x12
Intensif	300	3.72 M	~8.9	~3.0	x37
Power	1000	12.40 M	~29.8	~9.9	x124

Constat cle : le cap 100k = seulement ~8 messages/mois. Il est **trop bas** pour un usage assistant reel (profil Standard = 100 msg ≈ 1.2 M tokens, soit x12 le cap). Supporter un vrai assistant impose de relever le cap - le vrai sujet est donc le **plan tarifaire**, pas une limite technique.

Recommandations (etude des couts a approfondir avec vos vrais ratios)

- **Calibrer le cap par plan** plutot qu'un 100k global : ex. Starter ~250k (~20 msg), Pro ~1M (~80 msg), Scale ~3M+, et illimite en BYOK (le client paie sa cle).
- **Routage par modele** : taches simples (resume, extraction, FAQ) -> Haiku/Nova (3-30x moins cher) ; raisonnement/outils complexes -> Sonnet. Plus gros levier de cout disponible.
- **Garder multi-agent OFF** en prod (sinon 1 orchestrateur + jusqu'a 8 specialistes = x4-8 le cout/message).
- **Refacturer l'IA en add-on metre** au-dela d'un quota inclus par plan (le cout IA devient un revenu, pas une perte).
- **A approfondir** : mesurer en prod les vrais (msg/client, appels/msg, tokens/appel) via les logs de tokens deja traces (AiTokenBudgetService) pour remplacer ces hypotheses par des donnees reelles.

5. Coûts additionnels selon activation & pass-through

Ces coûts ne sont PAS dans le socle ci-dessus : ils dépendent de ce que chaque client active, et certains sont payés directement par le client (pass-through).

Options activables (coût pour Baitly si Baitly les fournit/refacture)

Option	Coût (ordre de grandeur)	Déclencheur
Channex (channel manager)	~1-5 EUR / logement / mois	si la sync OTA passe par Channex (revendeur)
e-signature QTSP (Yousign)	~0,5-2 EUR / signature	activate-only ; ou provider interne Clenzy = gratuit
KYC (Sumsu/Veriff/Onfido)	~1-3 EUR / vérification	si vérification voyageur activée
e-invoicing FR (PDP)	~centimes / facture	abonnement PDP + par-facture (échéance 2026-2027)
e-invoicing KSA (ZATCA)	~0 EUR API + KMS	API gratuite ; coût = KMS/HSM certificats (~0-30 EUR/mois)
WhatsApp (Meta Cloud)	~0,01-0,08 EUR / conversation	si messagerie WhatsApp activée
Mapbox (cartes/geocoding)	~0-quelques EUR	tier gratuit généreux ; cache Redis
Payouts (Wise/GoCardless)	frais / virement	versements propriétaires (faible)

Pass-through (PAYÉ par le client / le voyageur - PAS un coût Baitly)

- **Frais d'acquisition cartes** sur les paiements voyageurs : prélevés sur la transaction, pas un opex Baitly. **Migration prévue Stripe -> Airwallex** (cf. playbook) : tarif Airwallex sur devis, souvent compétitif vs Stripe, marge FX faible (~0,5-1%) ; Airwallex peut aussi consolider FX + payouts (remplacer Wise/GoCardless).
- **Commissions OTA** (Airbnb/Booking/Expedia ~15%) : prélevées par l'OTA.
- **Abonnements IoT & compta** (Nuki, Minut, Tuya, PennyLane, QuickBooks, Xero) : payés par le client à l'éditeur.
- **Passerelles paiement locales** (CMI, Payzone, PayTabs) : frais d'acquisition par transaction, cote client/marchand.

6. Reserves & leviers d'optimisation

Reserves methodologiques

- Tous les montants sont des **ordres de grandeur** : tarifs cloud/SaaS approximatifs (cutoff 2026-01), a confirmer par devis. Le modele est parametre (section 1) et doit etre recalibre avec vos vrais ratios d'usage.
- Les paliers infra (16->32 Go, puis BDD managee + S3) sont des seuils indicatifs ; le vrai declencheur est la **croissance disque** (photos stockees en BYTEA dans Postgres - migrer vers S3 a l'echelle).
- Le cout IA standard suppose l'usage **borne par le cap 100k tokens/org** ; un usage reel plus intensif suit le scenario section 4.
- 1 'client' = 1 organisation. Si vous raisonnez par 'utilisateur' (siege), le driver de cout reste l'usage IA des utilisateurs actifs, pas le nombre de comptes.

Leviers pour garder le cout bas

- Rester **mono-noeud** le plus longtemps possible (l'archi est prete : pgBouncer, replica commente, exporter).
- **Externaliser les photos en S3/Object Storage** (flag deja present) pour soulager BDD + backups.
- Garder **multi-agent OFF** en prod ; conserver le cap de tokens ; pousser le **BYOK** pour les gros consommateurs IA.
- Cloudflare Free + Let's Encrypt + monitoring self-hosted = 0 EUR de SaaS recurrent au-dela du serveur.